



Anthonius Valentino B. P. | JCDS 0408

# Hotel Booking Demand

---

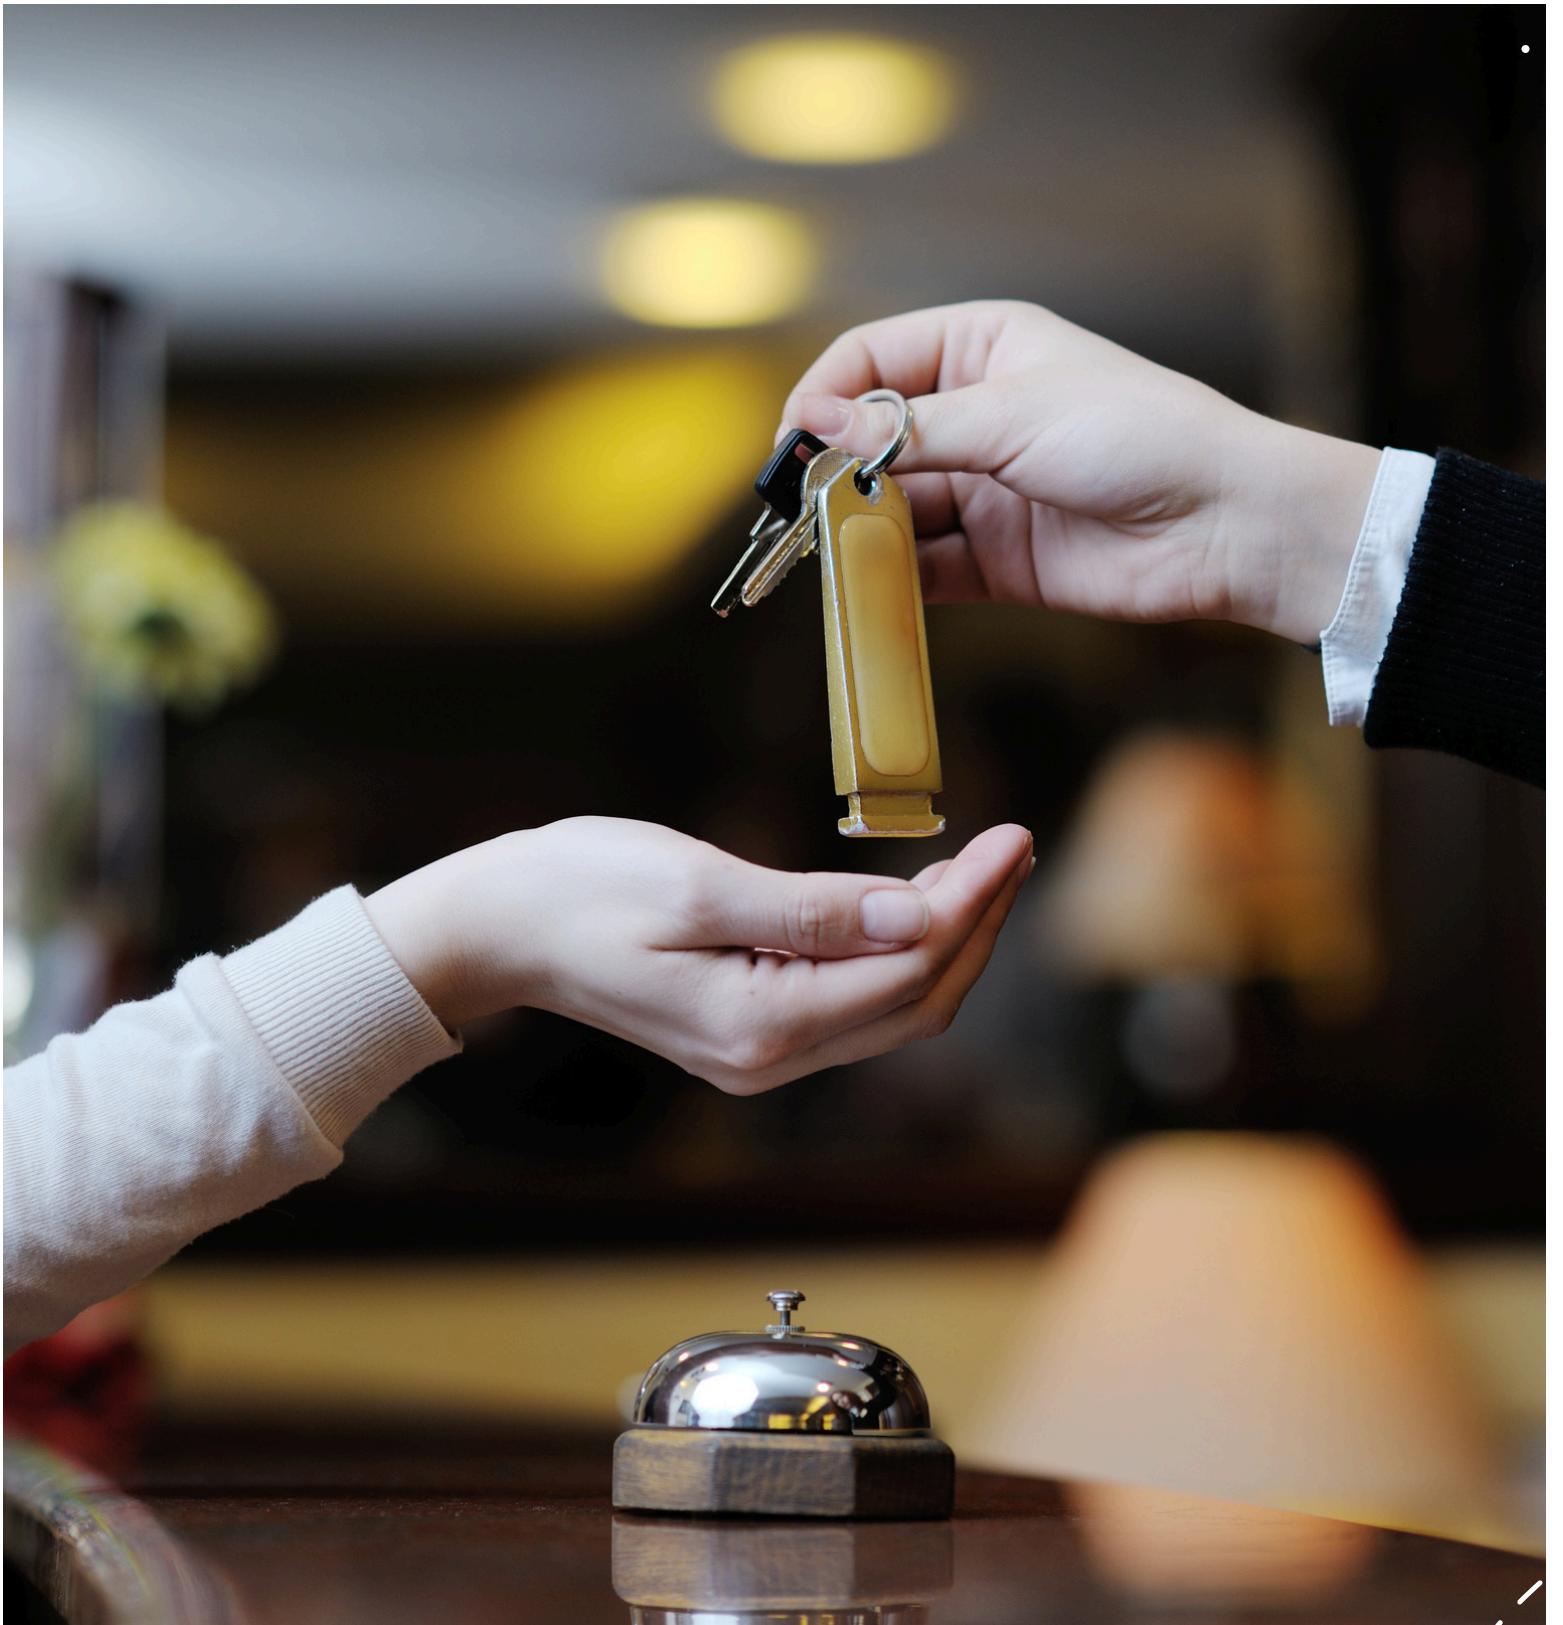
Presentasi Capstone 3 Modul Machine Learning

# BUSINESS PROBLEM

# PROBLEM STATEMENT

Dalam industri perhotelan, **revenue management memastikan kamar tersedia untuk tamu yang tepat dengan harga dan waktu yang tepat melalui channel distribusi yang sesuai.** Karena kamar adalah produk yang perishable, booking di muka digunakan untuk mengurangi opportunity cost.

Namun, **pembatalan booking menjadi risiko bagi hotel,** yang harus memastikan ketersediaan kamar sambil menghadapi potensi kerugian kapasitas kosong jika tamu membatalkan atau tidak hadir.



# HOTEL REVENUE MANAGEMENT (1)

## 1. Cost per Occupied Room (CPOR)

CPOR mengukur rata-rata biaya yang dikeluarkan hotel untuk setiap kamar yang ditempati tamu. Semakin rendah nilai CPOR, semakin tinggi potensi profitabilitas.

**CPOR = Total Operating Expenses / Total Number of Occupied Rooms**

## 2. Revenue per Available Room (RevPAR)

RevPAR menunjukkan jumlah pendapatan yang dihasilkan dari kamar yang tersedia sebagai inventori, terlepas dari apakah kamar tersebut terisi atau tidak.

**RevPAR = Total Room Revenue / (Total Number of Available Rooms x Days)**

## 3. Cost per Available Room (CostPAR)

CostPAR mengukur rata-rata biaya yang dikeluarkan untuk seluruh kamar yang tersedia, terlepas dari apakah kamar tersebut terisi atau tidak.

**CostPAR = Total Costs / (Total Number of Available Rooms x Days)**

## 4. Gross Operating Profit per Available Room (GOPPAR)

GOPPAR mengukur laba operasi bruto dari kamar yang tersedia dan memberikan gambaran lebih baik tentang performa finansial hotel.

**GOPPAR = Gross Operating Profit (GOP) / Total Number of Available Rooms**

# HOTEL REVENUE MANAGEMENT (2)

## 5. Labor per Available Room (LPAR)

LPAR mengukur efisiensi sumber daya tenaga kerja relatif terhadap jumlah kamar yang tersedia.

$$\text{LPAR} = \text{Total Labor Costs} / (\text{Total Number of Available Rooms} \times \text{Days})$$

## 6. Guest Acquisition Cost

GAC mengukur biaya rata-rata untuk mengakuisisi tamu baru

$$\text{GAC} = (\text{Guest Acquisition Costs} / \text{Total Room Revenue}) \times 100$$

# SIMULASI PERHITUNGAN (1)

## Tanpa Pembatalan

### 1. Cost per Occupied Room (CPOR)

Total Operating Expenses: \$500,000

Total Number of Occupied Rooms: 70

$$CPOR = \$500,000 / 70 = \$7,142.86$$

### 2. Revenue per Available Room (RevPAR)

Total Room Revenue: \$1,200,000

Total Number of Available Rooms: 100 (365 days)

$$RevPAR = \$1,200,000 / (100 \times 365) = \$32.88$$

### 3. Cost per Available Room (CostPAR)

Total Costs: \$500,000

Total Number of Available Rooms: 100 (365 days)

$$CostPAR = \$500,000 / (100 \times 365) = \$13.70$$

### 4. Gross Operating Profit per Available Room (GOPPAR)

Gross Operating Profit (GOP): \$700,000

Total Number of Available Rooms: 100 (365 days)

$$GOPPAR = \$700,000 / (100 \times 365) = \$19.18$$

## Terdapat Pembatalan

### 1. Cost per Occupied Room (CPOR)

Total Operating Expenses: \$500,000

Total Number of Occupied Rooms: 50 (**Menurun karena pembatalan**)

$$CPOR = \$500,000 / 50 = \$10,000. (**CPOR Meningkat**)$$

### 2. Revenue per Available Room (RevPAR)

Total Room Revenue: \$900,000 (**Menurun karena pembatalan**)

Total Number of Available Rooms: 100 (365 days)

$$RevPAR = \$900,000 / (100 \times 365) = \$24.66 (**RevPAR Menurun**)$$

### 3. Cost per Available Room (CostPAR)

Total Costs: \$400,000

Total Number of Available Rooms: 100 (365 days)

$$CostPAR = \$400,000 / (100 \times 365) = \$10.96.$$

### 4. Gross Operating Profit per Available Room (GOPPAR)

Gross Operating Profit (GOP): \$500,000 (**Menurun karena pembatalan**)

Total Number of Available Rooms: 100 (365 days)

$$GOPPAR = \$700,000 / (100 \times 365) = \$13.70 (**GOPPAR Menurun**)$$

# SIMULASI PERHITUNGAN (2)

## Tanpa Pembatalan

### 5. Labor per Available Room (LPAR)

LPAR = Total Labor Costs / (Total Number of Available Rooms x Days)

Contoh perhitungan:

Total Labor Costs: \$200,000

Total Number of Available Rooms: 100 (365 days)

$$\text{LPAR} = \$200,000 / (100 \times 365) = \$5.48$$

### 6. Guest Acquisition Costs (GAC)

Guest Acquisition Costs: \$150,000

Total Room Revenue: \$1,200,000

$$\text{GAC} = (\$150,000 / \$1,200,000) \times 100 = 12.5\%$$

## Terdapat Pembatalan

### 5. Labor per Available Room (LPAR)

LPAR = Total Labor Costs / (Total Number of Available Rooms x Days)

Contoh perhitungan:

Total Labor Costs: \$150,000

Total Number of Available Rooms: 100 (365 days)

$$\text{LPAR} = \$200,000 / (100 \times 365) = \$4.11$$

### 6. Guest Acquisition Costs (GAC)

Guest Acquisition Costs: \$200,000

Total Room Revenue: \$1,200,000

$$\text{GAC} = (\$200,000 / \$1,200,000) \times 100 = 22.2\%$$

# Dampak Pembatalan Booking Terhadap Revenue Management

- Pembatalan pemesanan yang signifikan, terutama selama musim puncak, berdampak negatif pada metrik-metrik ini dengan meningkatkan CPOR dan menurunkan RevPAR serta GOPPAR
- Manajemen pembatalan yang efektif sangat penting untuk menjaga stabilitas keuangan dan efisiensi operasional.

## Pemodelan Prediktif untuk Prediksi Pembatalan:

- Implementasi model machine learning untuk memprediksi pembatalan pemesanan dapat membantu hotel mengoptimalkan manajemen pendapatan dan mengurangi ketidakpastian dalam pengambilan keputusan.
- Dengan memprediksi pembatalan secara akurat, hotel dapat meningkatkan manajemen inventori dan strategi harga mereka.

# ANALTIC APPROACH & METRIC SELECTION

# MODEL KLASIFIKASI SUPERVISED

- Masalah ini dapat diselesaikan dengan algoritma model klasifikasi karena tujuan utamanya adalah memprediksi apakah seorang tamu akan membatalkan pemesanan (kelas positif) atau tidak (kelas negatif).
- Model klasifikasi cocok digunakan untuk masalah ini karena mampu mempelajari pola dari data historis untuk mengidentifikasi fitur-fitur yang mempengaruhi kemungkinan pembatalan.

## MODEL YANG AKAN DIEVALUASI:

- 1. Logistic Regression**
- 2. K-Neighbors Classifier**
- 3. Decision Tree**
- 4. Voting Classifier (Hard & Soft)**
- 5. Stacking Classifier**
- 6. Random Forest Classifier**
- 7. AdaBoost Classifier**
- 8. Gradient Boosting Classifier**
- 9. XGB Classifier**

# PEMILIHAN METRICS MODEL (1)

## Precision

### Cost per Occupied Room (CPOR)

Dengan memprioritaskan precision, model dapat memprediksi pembatalan secara akurat dan menghindari biaya persiapan yang tidak perlu.

Total Operating Expenses: \$480,000 (berkurang karena preparation cost yang lebih sedikit)

Total Number of Occupied Rooms: 70

$$\mathbf{CPOR = \$480,000 / 70 = \$6,857.14}$$

### Revenue per Available Room (RevPAR)

Precision yang tinggi dapat menyebabkan sedikit kehilangan revenue karena pembatalan yang tidak terprediksi (false negatives).

Total Room Revenue: \$1,150,000 (sedikit berkurang karena peluang yang terlewatkan)

Total Number of Available Rooms : 100

$$\mathbf{RevPAR = \$1,150,000 / (100 \times 365) = \$31.51}$$

### Guest Acquisition Costs (GAC)

Pemasaran menjadi lebih terarah, sehingga mengurangi pemborosan.

Guest Acquisition Costs: \$145,000

$$\mathbf{GAC = (\$145,000 / \$1,150,000) \times 100 = 12.61\%}$$

## Recall

### Cost per Occupied Room (CPOR)

Dengan fokus pada recall, hotel mempersiapkan lebih banyak pembatalan, termasuk yang mungkin tidak terjadi, meningkatkan potensi biaya.

**Total Operating Expenses:** \$520,000 (meningkat karena preparation cost bertambah)

**Total Number of Occupied Rooms:** 65 (karena lebih banyak pembatalan yang diantisipasi dan beberapa kamar yang tidak disiapkan)

$$\mathbf{CPOR= \$520,000 / 65 = \$8,000}$$

### Revenue per Available Room (RevPAR)

Memprediksi lebih banyak pembatalan membantu hotel menangani last-minute bookings dengan lebih baik.

**Total Room Revenue:** \$1,210,000 (sedikit meningkat karena penanganan last minute booking yang lebih baik)

**Total Number of Available Rooms:** 100

$$\mathbf{RevPAR= \$1,210,000 / (100 \times 365) = \$33.15}$$

### Guest Acquisition Costs (GAC)

Pemasaran dapat diperluas untuk mencegah pembatalan oleh tamu potensial.

**Guest Acquisition Costs:** \$160,000

$$\mathbf{GAC = (\$160,000 / \$1,210,000) \times 100 = 13.22\%}$$

# PEMILIHAN METRICS MODEL (2)

## Key Takeaways:

1. **High Recall** menghasilkan **pendapatan per kamar** yang tersedia **lebih tinggi (\$33.15 vs. \$31.51)**, tetapi juga menimbulkan **biaya yang lebih tinggi (CPOR dan GAC)**.
2. **High Precision** menghasilkan **biaya yang lebih rendah** dan **sedikit pendapatan yang lebih rendah**.
3. **High Precision** kemungkinan akan **lebih menguntungkan secara keseluruhan** karena penghematan biaya (CPOR dan GAC yang lebih rendah) melebihi sedikit peningkatan pendapatan dalam skenario

## Balance Between Precision and Recall

1. **F0.5** Score Fokus pada **Precision**: Memberi bobot lebih pada precision dibanding recall, cocok ketika cost **false positives** lebih mahal daripada false negatives.
2. Ideal untuk Pemesanan Hotel: Berguna jika biaya **salah prediksi pembatalan** (misalnya, diskon yang tidak perlu, penyesuaian ketersediaan kamar) **lebih tinggi** daripada kehilangan beberapa pembatalan.
3. Mengurangi Biaya yang Tidak Perlu: Dengan fokus pada F0.5 score, model **mengurangi false positives**, memastikan sumber daya dan insentif hanya untuk pemesanan yang paling mungkin dibatalkan, **sehingga menurunkan biaya yang tidak perlu**.

# DATA UNDERSTANDING & PRE-PROCESSING

# COLUMN DESCRIPTION

	feature	data_type	null	negative	n_unique	sample_unique
0	country	object	1.156636	False	162	[UMI, LUX, COL, FRA, CHN, SWE, CIV, BEL, USA, ...]
1	market_segment	object	0.000000	False	8	[Online TA, Direct, Groups, Offline TA/TO, Com...
2	previous_cancellations	int64	0.000000	False	15	[0, 2, 1, 3, 11, 6, 13, 5, 4, 21, 26, 14, 24, ...]
3	booking_changes	int64	0.000000	False	19	[0, 5, 1, 3, 2, 4, 6, 7, 8, 17, 10, 13, 12, 14...
4	deposit_type	object	0.000000	False	3	[No Deposit, Refundable, Non Refund]
5	days_in_waiting_list	int64	0.000000	False	115	[0, 97, 4, 113, 87, 48, 63, 59, 8, 183, 77, 15...
6	customer_type	object	0.000000	False	4	[Transient, Transient-Party, Group, Contract]
7	reserved_room_type	object	0.000000	False	10	[E, D, G, A, F, C, H, B, P, L]
8	required_car_parking_spaces	int64	0.000000	False	5	[0, 1, 2, 8, 3]
9	total_of_special_requests	int64	0.000000	False	6	[1, 0, 3, 2, 4, 5]
10	is_canceled	object	0.000000	False	2	[Yes, No]

# DATA PREPROCESSING PIPELINE

Pipeline penting dalam pembuatan model klasifikasi machine learning karena memastikan alur pemrosesan data yang konsisten dan otomatis, dari penanganan data yang hilang, nilai outlier, hingga pemilihan fitur dan penyeimbangan data.

Technique	Action 1	Action 2
Handling High Cardinality	Mengelompokkan negara menjadi top 9 dan sisanya Other	
Handling Missing Value	Missing value pada kolom country akan diisi Other	
Handling Rare Value	Rare Value pada kolom market_segment	
Handling Outlier	Menggunakan winsorize dengan limit 1% untuk kolom booking_changes dan required_car_parking_space	Tidak dilakukan Handling outlier dalam bentuk apapun
Polynomial Features	Menggunaan degree = 1 (Tidak diberi perlakuan)	Menggunakan degree > 1
Encoding	One Hot Encoding untuk kolom Country, Market Segment, Deposit Type, Customer Type dan Reserved Room.	
Robust Scaling	Transformasi skala dari tiap feature dengan menggunakan robust scaler	Tidak dilakukan scaling dalam bentuk apapun
Imbalance Data Handling	Resampling dengan SMOTE	Resampling dengan ROS

# MODEL SELECTION & EVALUATION

# MODEL SELECTION (1)

## Stratified K-Fold Cross-Validation:

- Cross-validation dengan 'StratifiedKFold' digunakan untuk mengevaluasi generalisasi model ke dataset independen.
- Dataset dibagi menjadi beberapa subset training dan validasi secara berulang, dan model dilatih serta dievaluasi berdasarkan subset ini.
- Metode ini membagi dataset menjadi 5 fold, memastikan setiap fold memiliki proporsi label kelas yang sama dengan dataset asli.

	Model	Mean F0.5	Std F0.5	All F0.5 Scores
3	GradientBoostingClassifier	0.529799	0.049699	[0.5343, 0.5844, 0.5804, 0.4554, 0.4945]
7	StackingClassifier	0.522249	0.030032	[0.5004, 0.5495, 0.5637, 0.4834, 0.5144]
4	AdaBoostClassifier	0.504089	0.034876	[0.4722, 0.5073, 0.5551, 0.4598, 0.5261]
9	XGBClassifier	0.495832	0.037535	[0.4836, 0.554, 0.5238, 0.4602, 0.4575]
0	LogisticRegression	0.494891	0.028040	[0.477, 0.5044, 0.5412, 0.4578, 0.494]
5	VotingClassifier_Hard	0.434991	0.047598	[0.4343, 0.5023, 0.4721, 0.3789, 0.3873]
1	KNeighborsClassifier	0.421864	0.038737	[0.4259, 0.4663, 0.4609, 0.3865, 0.3696]
6	VotingClassifier_Soft	0.389165	0.049957	[0.4025, 0.4456, 0.434, 0.3484, 0.3154]
8	RandomForestClassifier	0.389021	0.043276	[0.3992, 0.453, 0.411, 0.3357, 0.3462]
2	DecisionTreeClassifier	0.378724	0.053301	[0.3653, 0.4669, 0.4066, 0.3371, 0.3176]

# MODEL SELECTION (2)

Hasil penggunaan model pipeline dan beberapa model ke dalam test set adalah sebagai berikut:

	Model	F0.5 (Test Set)
3	GradientBoostingClassifier	0.534569
7	StackingClassifier	0.530764
4	AdaBoostClassifier	0.519785
9	XGBClassifier	0.500859
0	LogisticRegression	0.486467
5	VotingClassifier_Hard	0.408786
8	RandomForestClassifier	0.396905
1	KNeighborsClassifier	0.387663
6	VotingClassifier_Soft	0.384418
2	DecisionTreeClassifier	0.370737

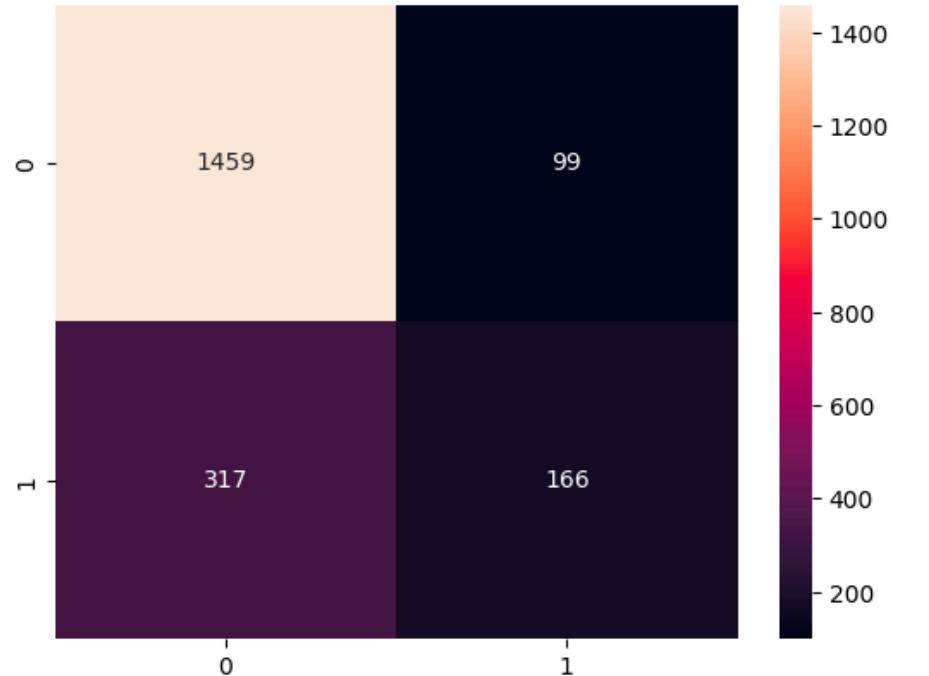
# HYPER PARAMETER TUNING (1)

- **Hyperparameter Tuning**: Proses untuk mengoptimalkan parameter yang tidak dipelajari oleh model selama training.
- **Tujuan**: Meningkatkan kinerja lima model teratas dengan mencari kombinasi hyperparameter terbaik.
- **Parameter Contoh**: Jumlah pohon dalam random forest, learning rate dalam gradient boosting.
- **Hasil yang Diharapkan**: Meningkatkan nilai F 0.5 dan performa model secara keseluruhan

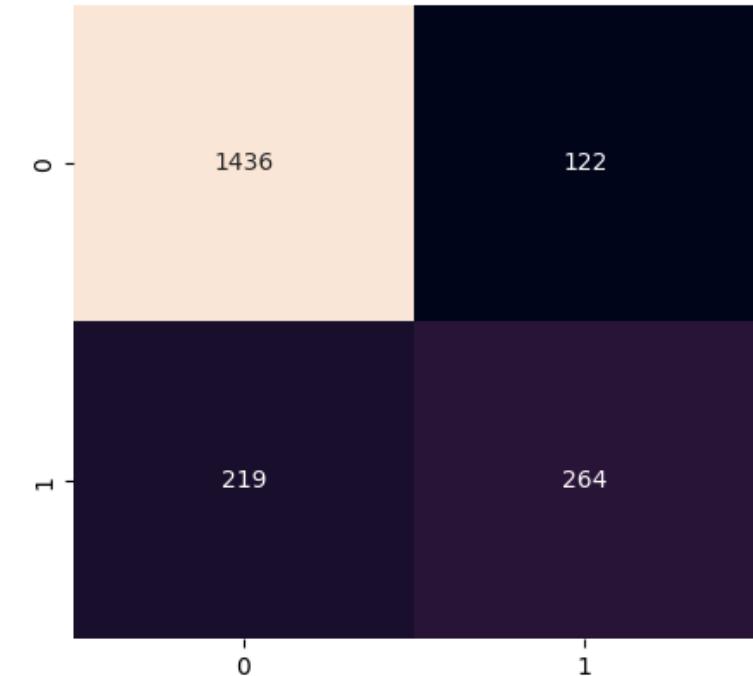
Nama Model	F 0.5 Before Tune	F 0.5 After Tune
Gradient Boosting	0.5298	0.5307
<b>Stacking</b>	<b>0.5222</b>	<b>0.6218</b>
AdaBoost	0.5040	0.5319
XGBoost	0.4958	0.5336
Logistic Regression	0.4948	0.5011

# HYPER PARAMETER TUNING (2)

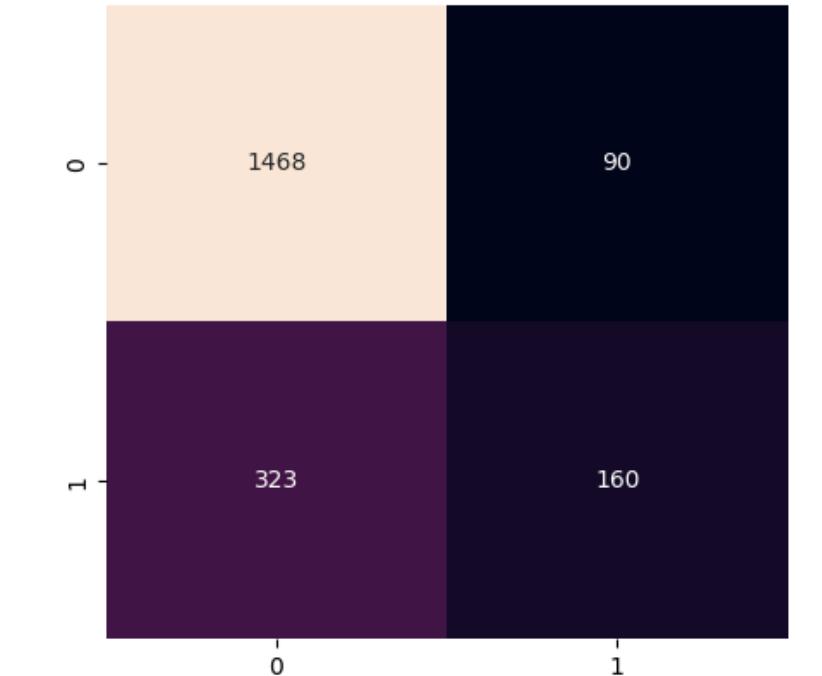
Gradient Boosting



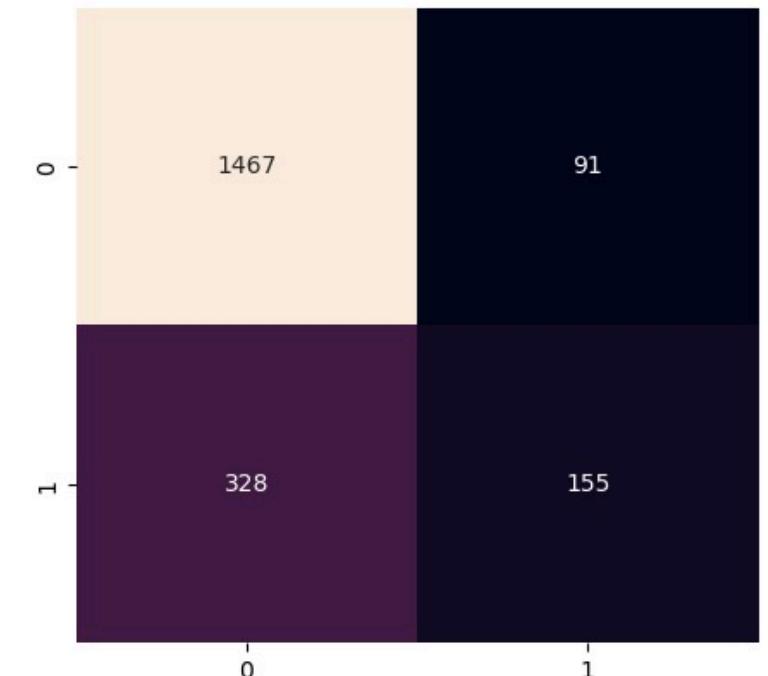
Stacking



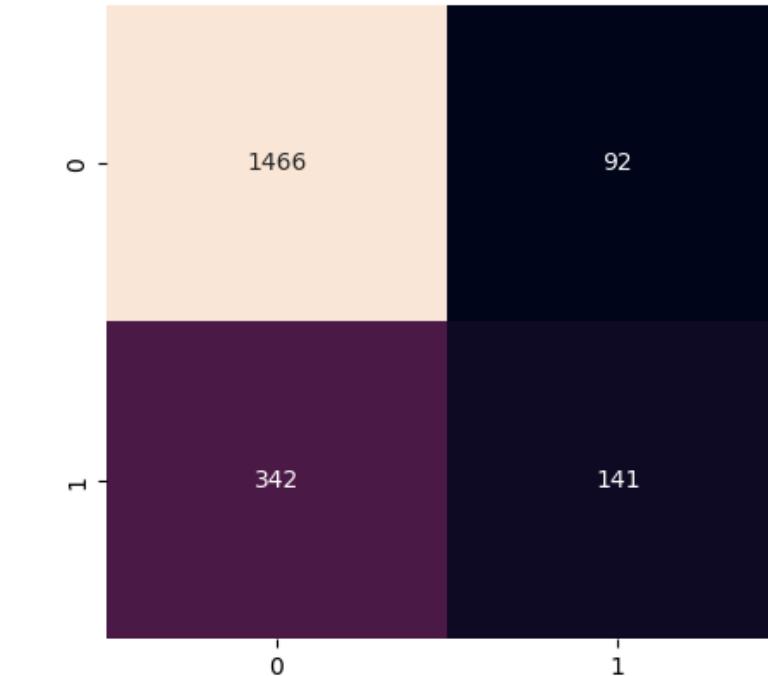
AdaBoost



XGB



Logistic Regression



# BEST MODEL

- **Stacking** adalah metode ensemble yang menggabungkan beberapa algoritma untuk meningkatkan akurasi prediksi. Setiap base learner menangani data secara berbeda:
- **Decision Tree:** Memisahkan data berdasarkan fitur, efektif untuk hubungan non-linear.
- **K-Nearest Neighbors (KNN):** Memprediksi berdasarkan jarak ke tetangga terdekat, baik untuk pola lokal.
- **Gradient Boosting:** Memperbaiki kesalahan model sebelumnya, cocok untuk data kompleks.
- **Logistic Regression** digunakan sebagai meta-learner untuk menggabungkan prediksi dari base learners dan meningkatkan akurasi keseluruhan.

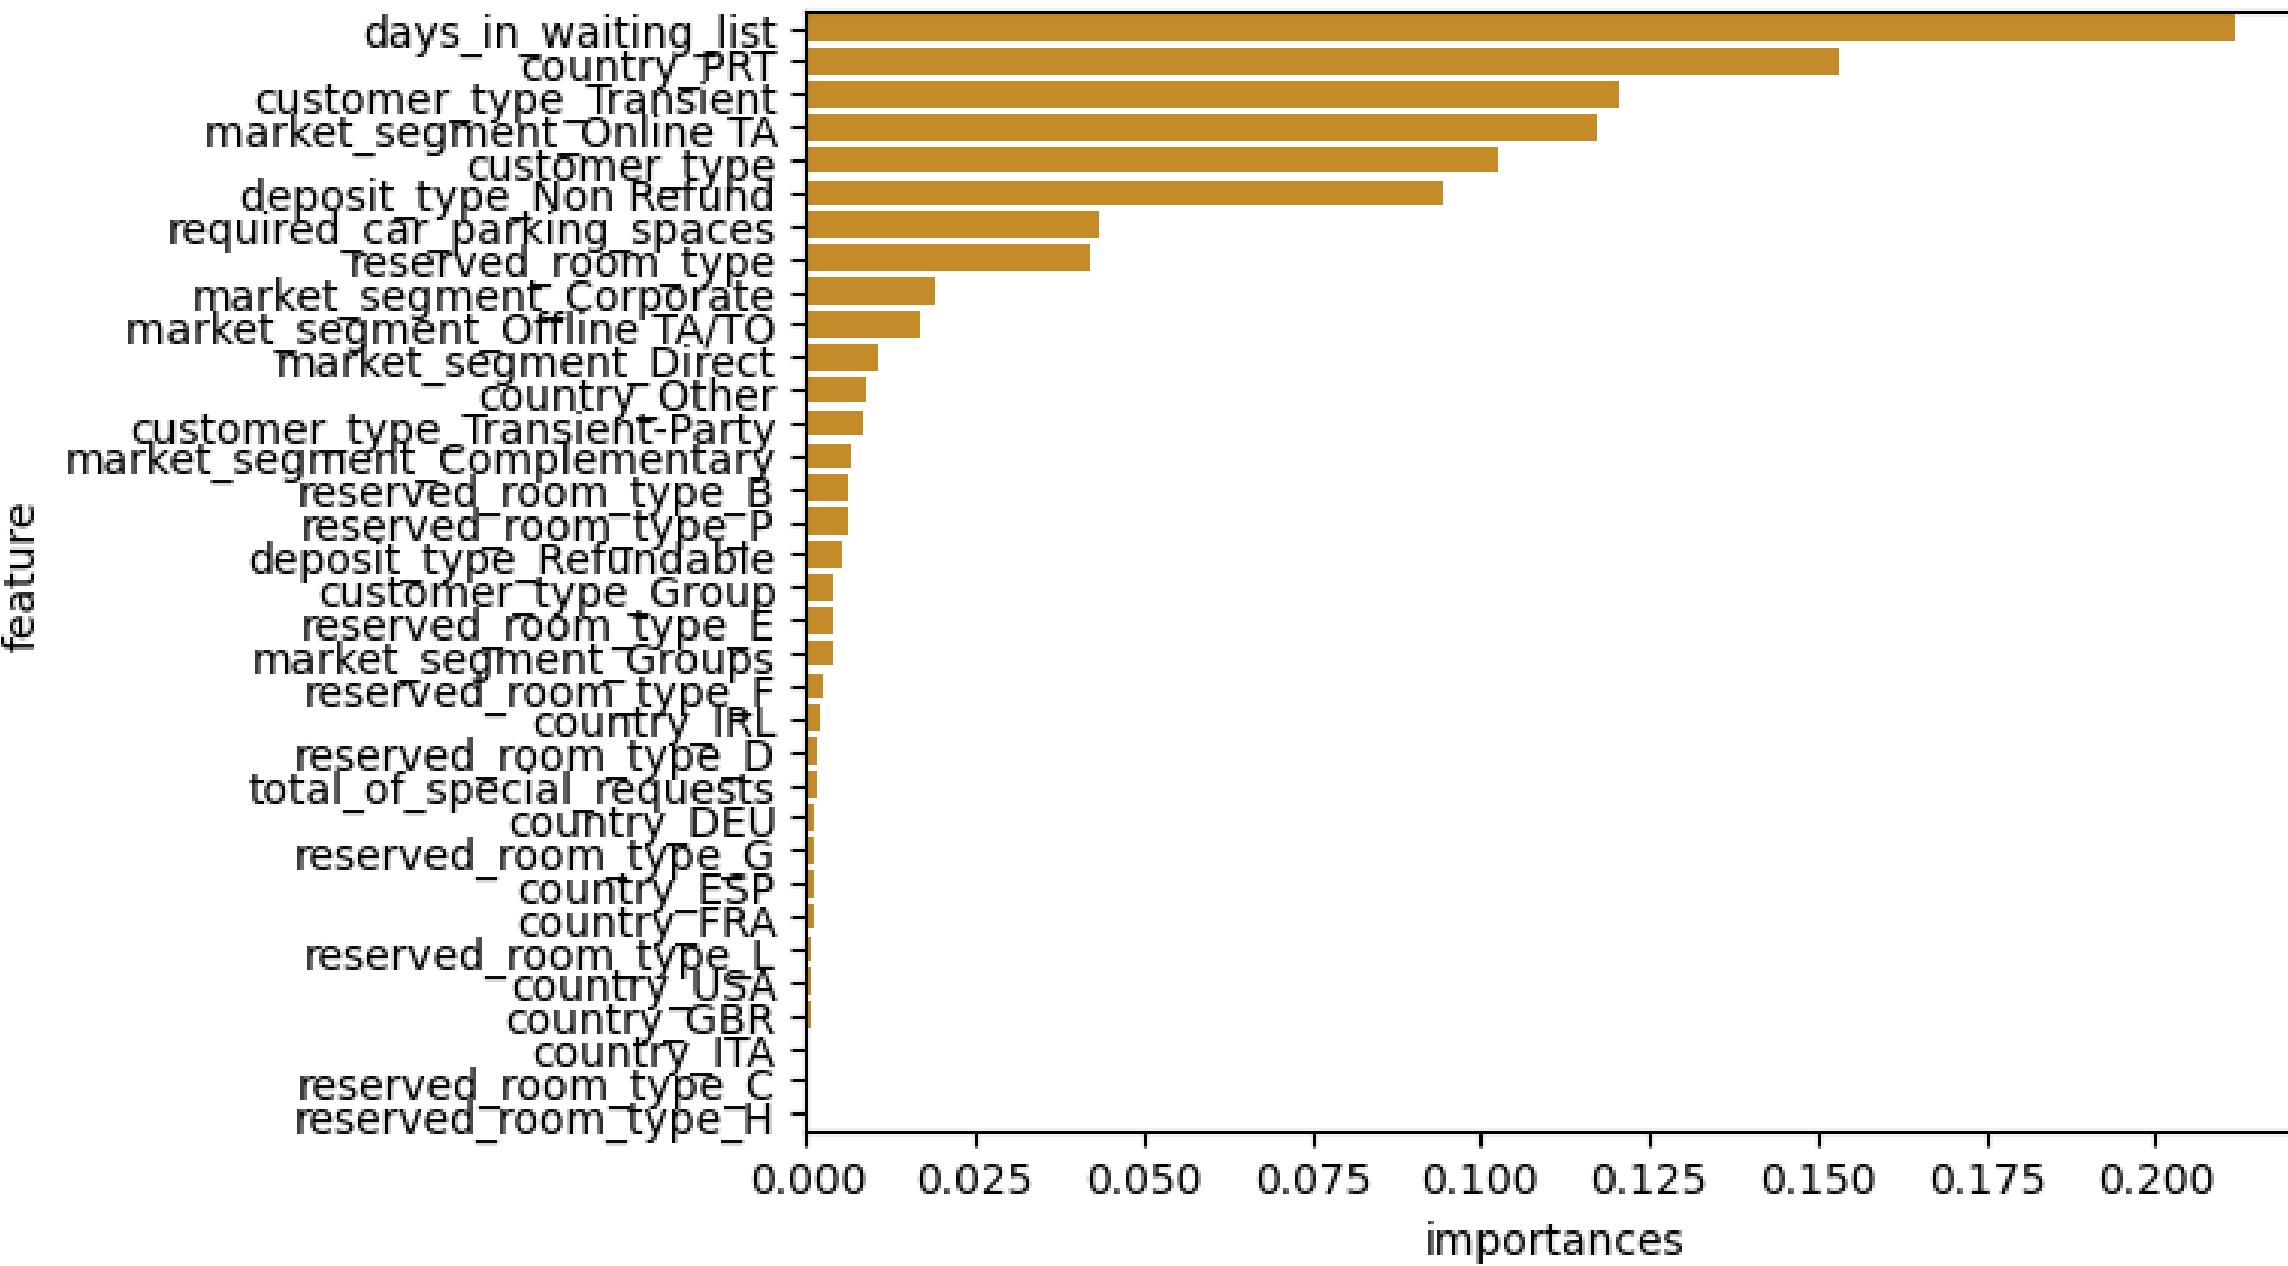
## Best Model Parameters for Stacking Model:

- `scaler`: RobustScaler()
- `resampler`: None
- `poly_transform`: PolynomialFeaturesTransformer
  - **columns**:
    - 'required\_car\_parking\_spaces'
    - 'previous\_cancellations'
    - 'total\_of\_special\_requests'
    - 'booking\_changes'
    - 'days\_in\_waiting\_list'
  - **degree**: 1
- `outlier`: HandlingOutliers()
- `model_knn_weights`: 'distance'
- `model_knn_n_neighbors`: 11
- `model_gb_subsample`: 0.8
- `model_gb_n_estimators`: 70
- `model_gb_max_depth`: 3
- `model_gb_learning_rate`: 0.14
- `model_final_estimator_penalty`: 'l2'
- `model_final_estimator_C`: np.float64(3.1622776601683795)
- `model_dt_min_samples_split`: 3
- `model_dt_min_samples_leaf`: 2
- `model_dt_max_depth`: 8

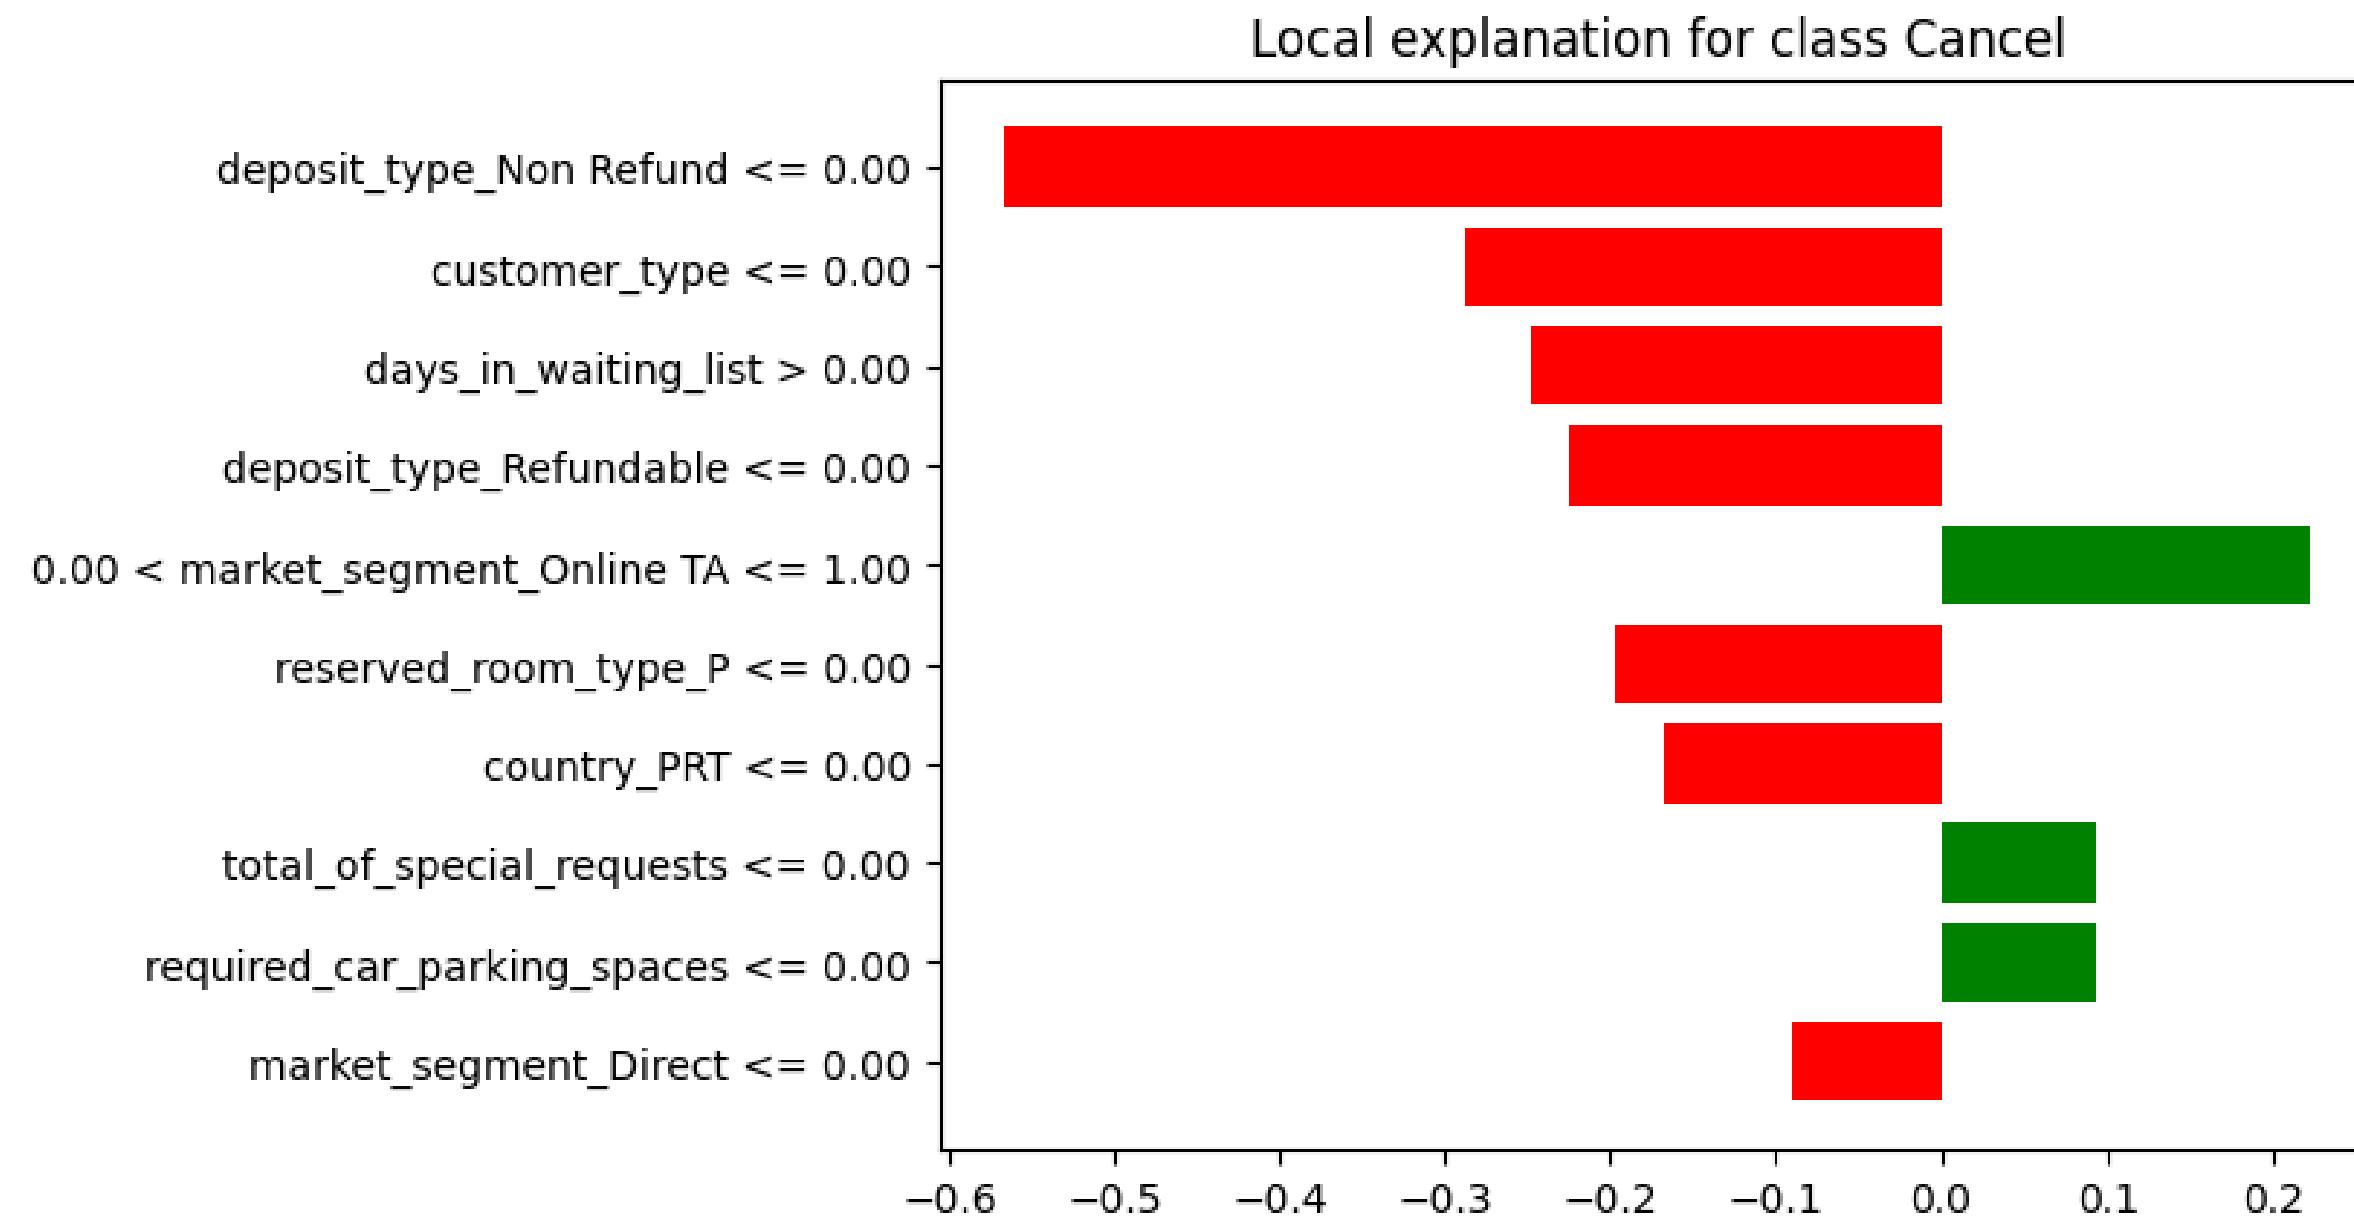
Best F0.5 Score: 0.6218599577640254

# BEST MODEL (FEATURE IMPORTANCES) (1)

- days\_in\_waiting\_list (0.2119): Faktor yang sangat berpengaruh dalam memprediksi pembatalan.
- country\_PRT (0.1533): Signifikan dalam memprediksi kemungkinan pembatalan untuk tamu dari Portugal.
- customer\_type\_Transient (0.1205): Penting untuk mengidentifikasi kecenderungan pembatalan di antara tamu sementara.
- market\_segment\_Online TA (0.1173): Kunci dalam menilai pembatalan untuk reservasi yang dibuat melalui agen perjalanan online.
- deposit\_type\_Non Refund (0.0944): Mempengaruhi prediksi pembatalan di mana deposit tidak dapat dikembalikan.



# BEST MODEL (FEATURE IMPORTANCES) (2)



- **deposit\_type\_Non Refund ( $\leq 0.00$ )**: Deposit yang tidak dapat dikembalikan secara signifikan meningkatkan kemungkinan pembatalan.
- **customer\_type ( $\leq 0.00$ )**: Jenis pelanggan tertentu, terutama yang tidak terikat kontrak (misalnya, pelanggan transient), lebih mungkin membatalkan.
- **days\_in\_waiting\_list ( $> 0.00$ )**: Waktu tunggu yang lebih lama dikaitkan dengan kemungkinan pembatalan yang lebih tinggi.
- **market\_segment\_Online TA ( $0.00 < \text{nilai} \leq 1.00$ )**: Reservasi melalui agen perjalanan online lebih mungkin dibatalkan.
- **country\_PRT ( $\leq 0.00$ )**: Tamu dari Portugal lebih cenderung membatalkan reservasi mereka.

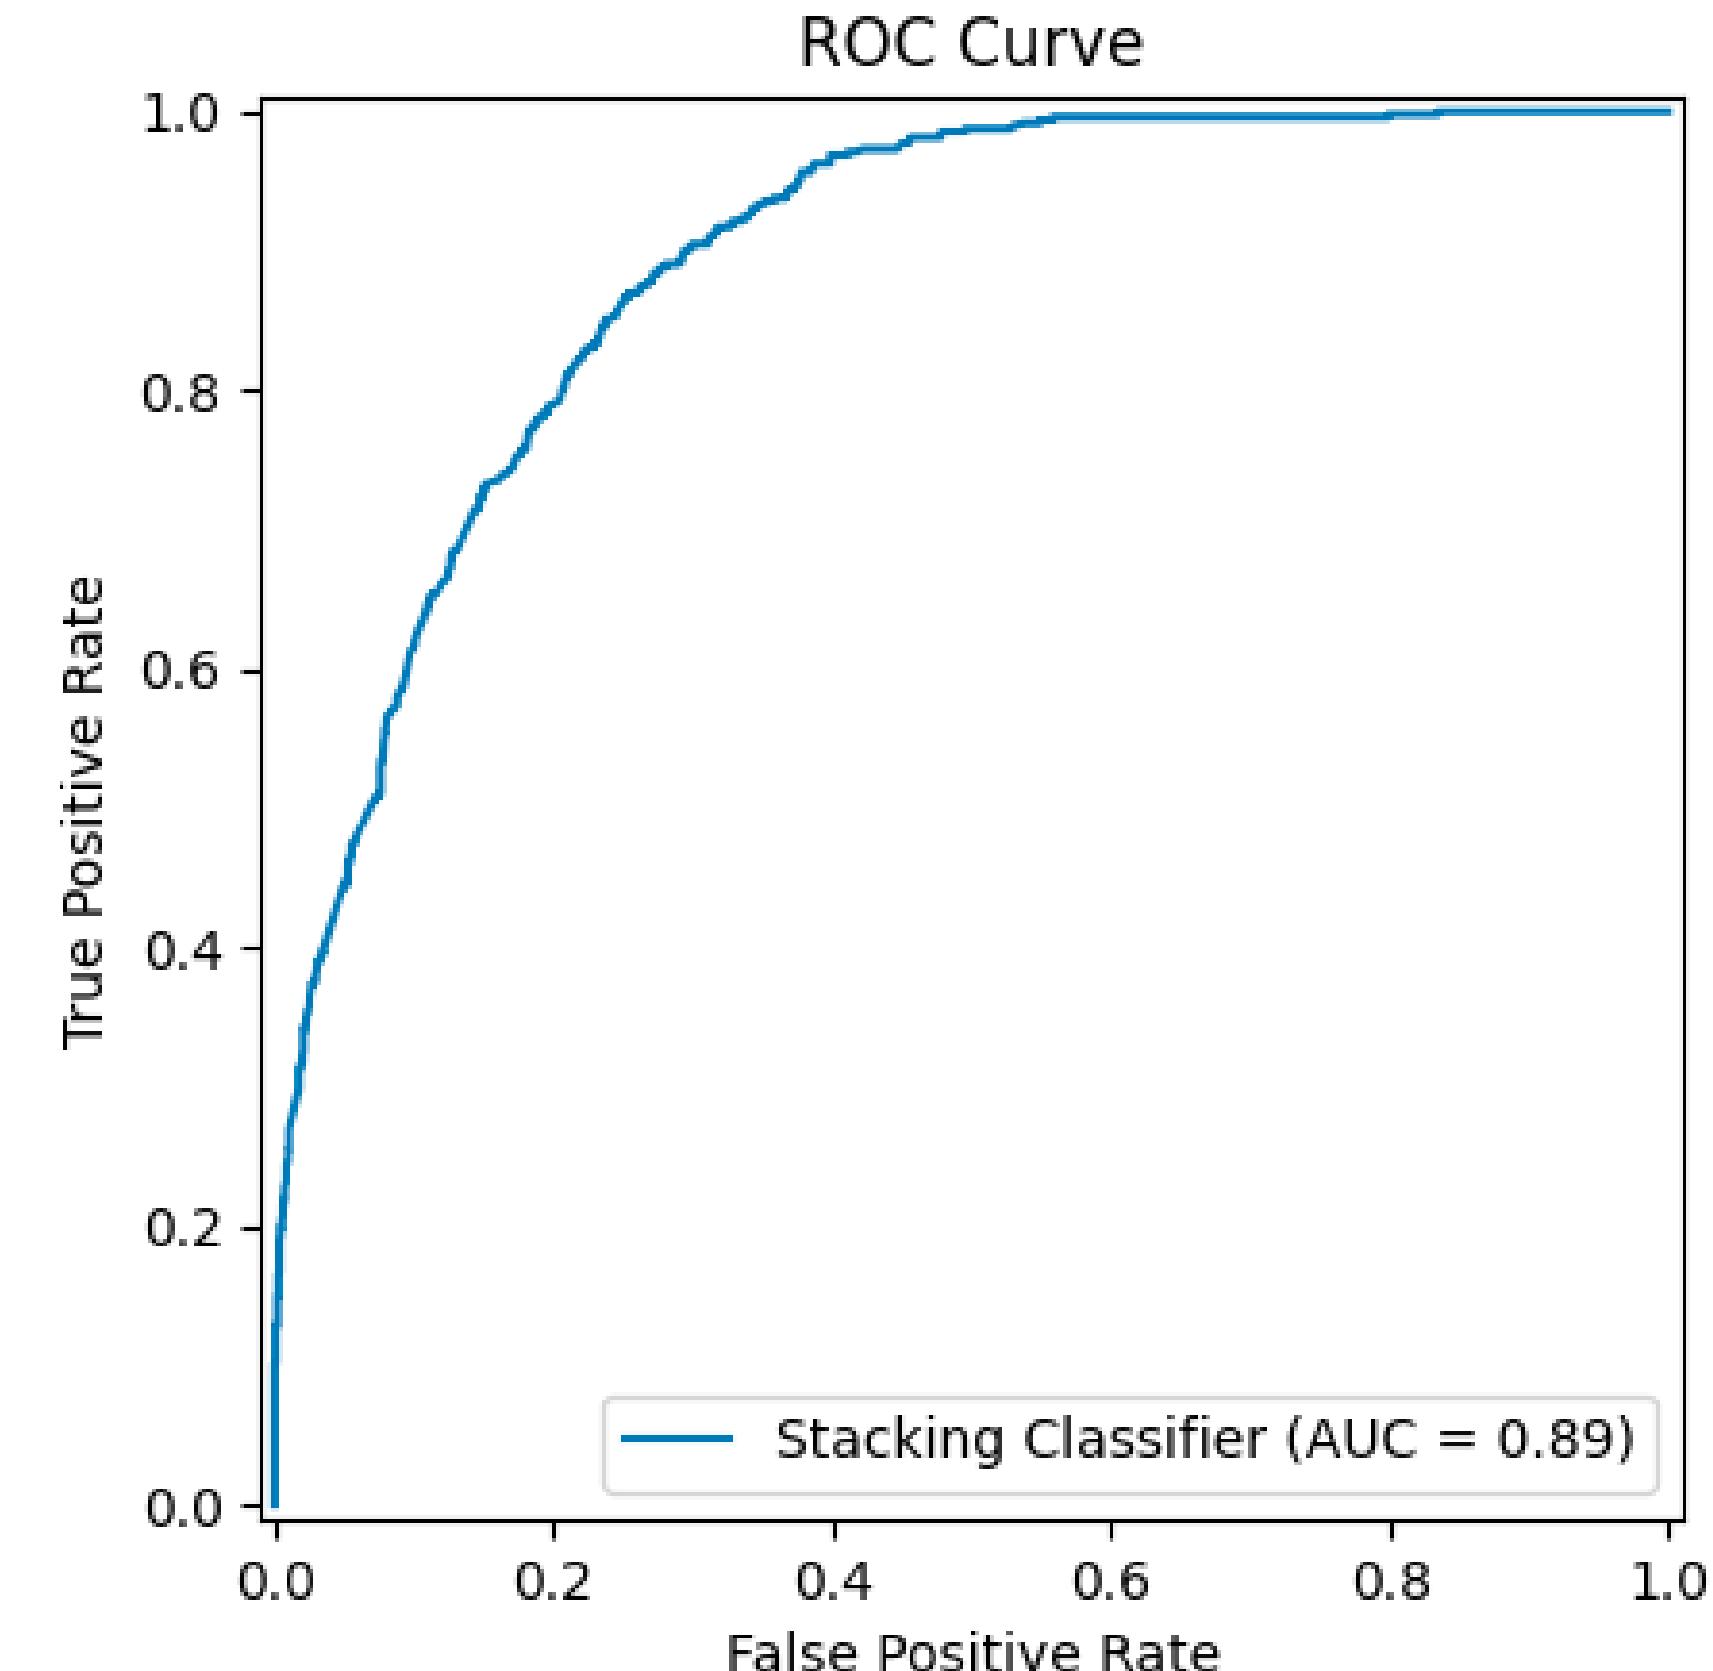
# BEST MODEL (ROC DAN AUC)

## Kelebihan:

1. AUC Tinggi (0.89)
2. True Positive Tinggi, False Positive Rendah

## Keterbatasan:

1. False Positives/Negatives
2. Trade-Off Sensitivitas vs. Spesifitas:



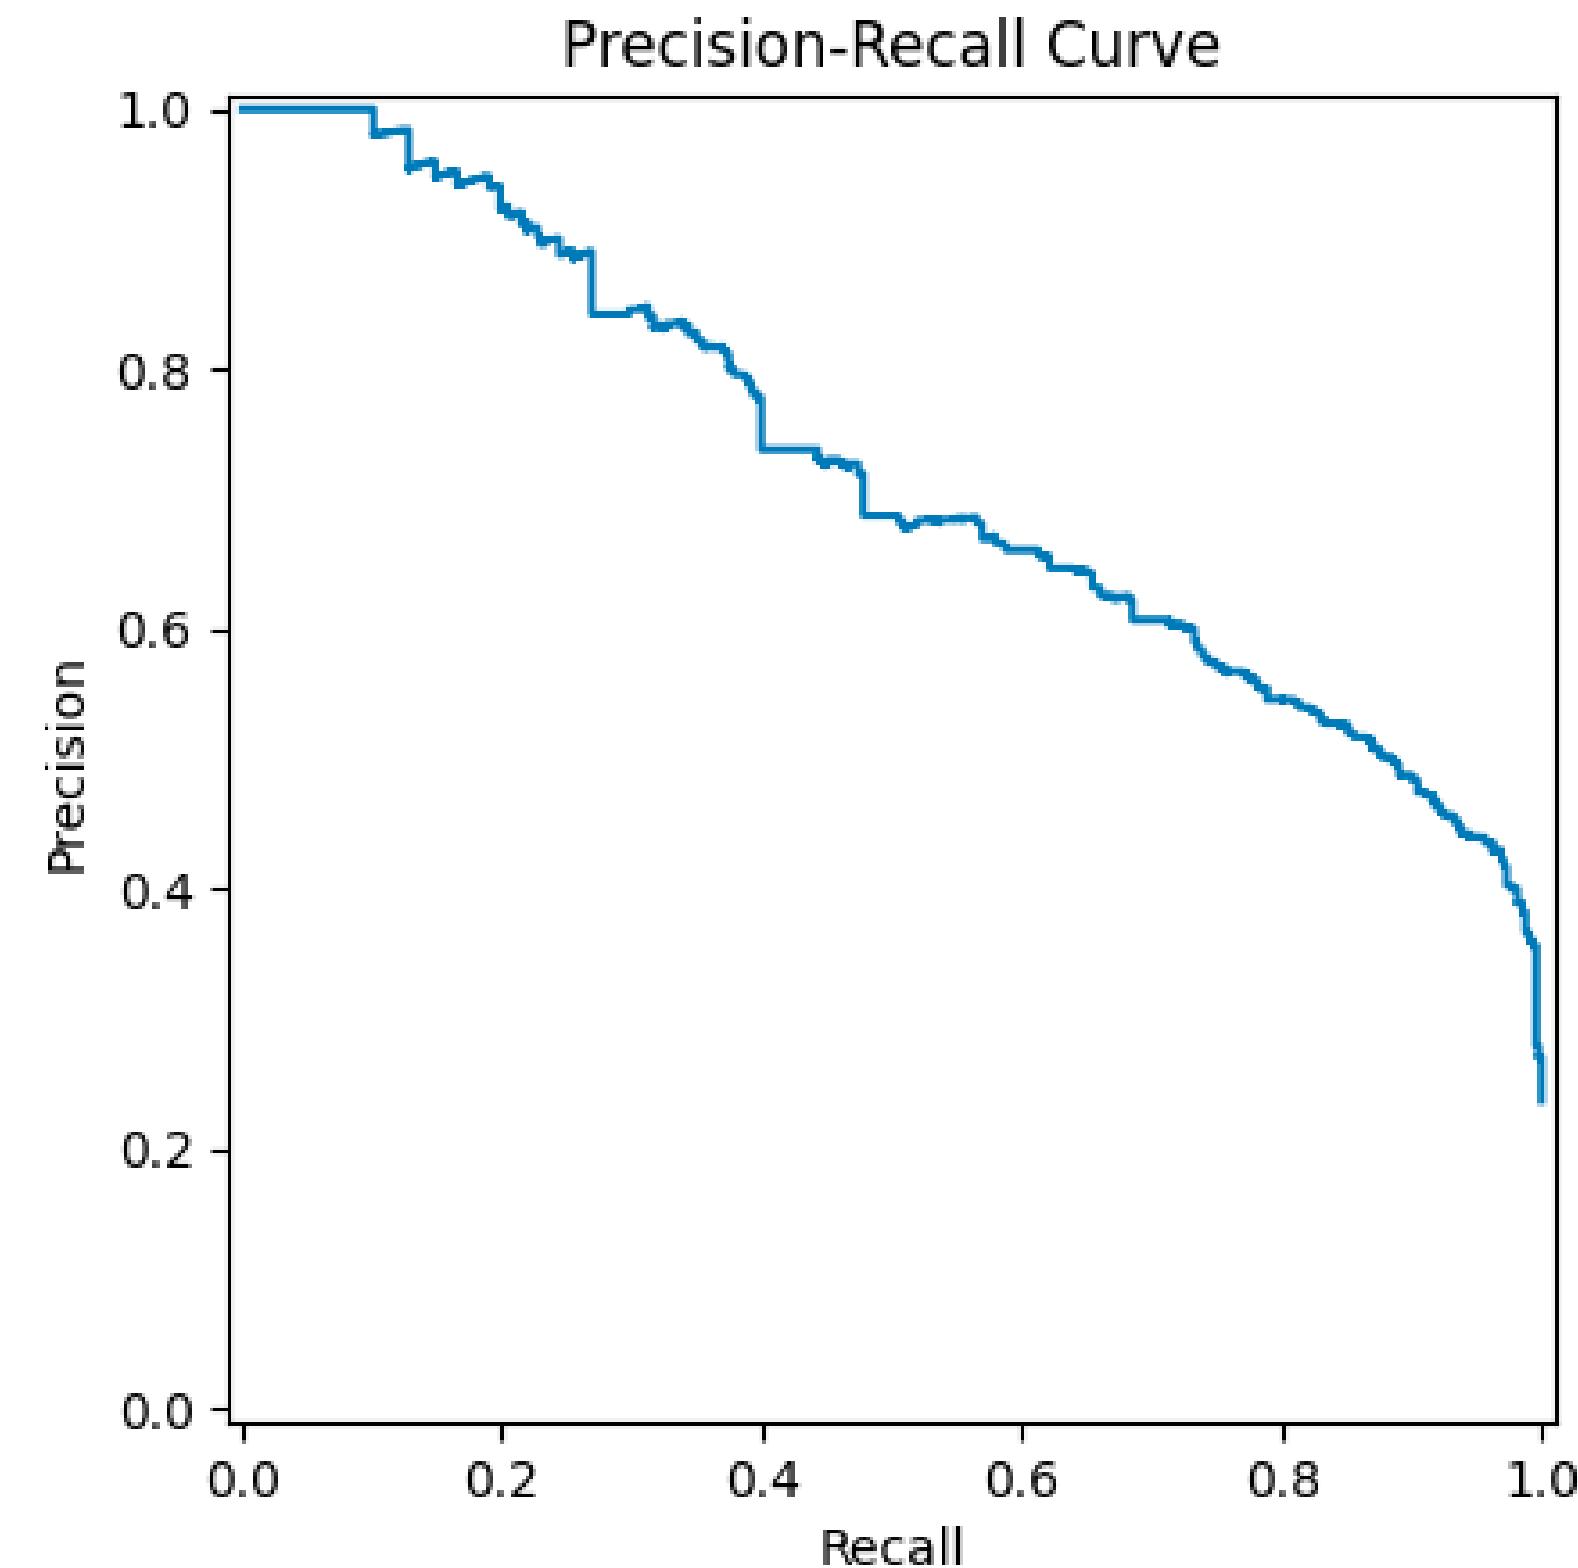
# BEST MODEL (PRECISION-RECALL CURVE)

## Aspek Keunggulan Model:

1. Precision Tinggi pada Recall Rendah
2. Efektif untuk Situasi dengan Recall Rendah dan Precision Tinggi

## Keterbatasan Model:

1. Precision Menurun Saat Recall Meningkat
2. Trade-Off Antara Precision dan Recall



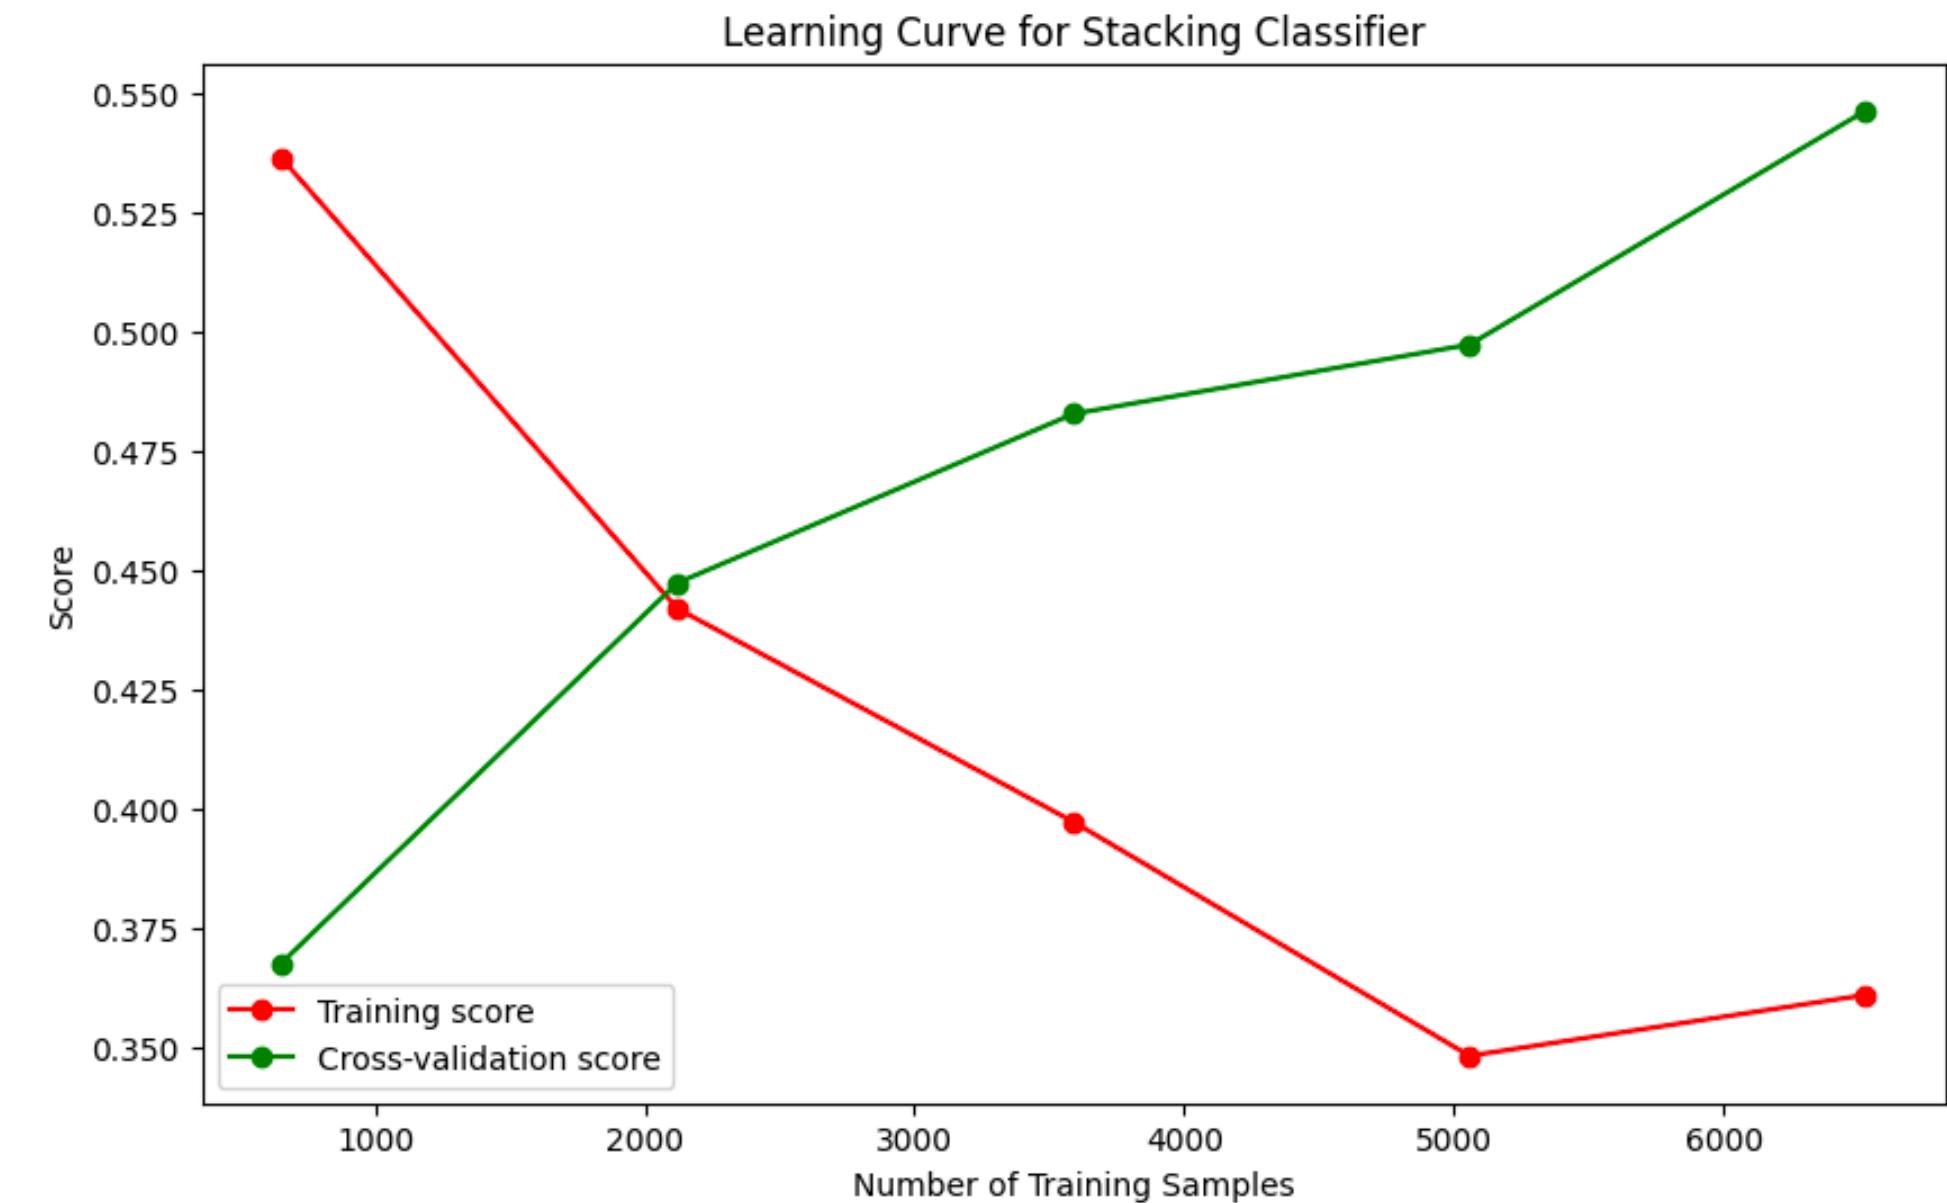
# BEST MODEL (LEARNING CURVE)

## Aspek Keunggulan Model:

1. Peningkatan Skor Cross Validation dengan penambahan data
2. Potensi Peningkatan Generalisasi

## Keterbatasan Model:

1. Penurunan Skor Trainng dengan Penambahan Data
2. Kesenjangan Skor Training dan Cross-Validation



# COST BENEFIT ANALYSIS

- **CPOR (Cost per Occupied Room):** Dengan machine learning, CPOR turun menjadi \$2,708.33 dibandingkan \$8,461.54 tanpa machine learning, menunjukkan penghematan biaya yang signifikan dan manajemen okupansi yang lebih baik.
- **RevPAR (Revenue per Available Room):** Dengan machine learning, RevPAR meningkat ke \$31.51 dari \$30.14 tanpa machine learning, menunjukkan optimisasi pendapatan yang lebih baik melalui prediksi yang akurat.
- **GAC (Guest Acquisition Costs):** GAC berkurang menjadi 13.91% dengan machine learning dibandingkan 16.36% tanpa machine learning, menunjukkan pemasaran yang lebih efektif dan terarah dengan bantuan analitik prediktif.

# CONCLUSION & RECOMMENDATION

# CONCLUSION

1. **Model Terbaik:** Stacking Classifier dipilih sebagai model terbaik setelah hyperparameter tuning, meningkatkan F0.5 score dari 0.522 menjadi 0.6218, menunjukkan efektivitas dalam memprediksi pembatalan booking hotel.
2. **Keunggulan Stacking Classifier:** Confusion matrix menunjukkan model ini memiliki True Positives tertinggi (264), penting untuk menghindari overbooking dan meningkatkan manajemen sumber daya.
3. **Dampak pada Revenue Management:** Machine learning mengurangi Cost per Occupied Room (CPOR) sebesar 67.98%, meningkatkan Revenue per Available Room (RevPAR), dan menurunkan Guest Acquisition Costs (GAC).
4. **Feature Importance:** Fitur paling signifikan untuk prediksi pembatalan adalah `days\_in\_waiting\_list`, diikuti oleh `country\_PRT`, `customer\_type\_transient`, `market\_segment\_Online TA`, dan `deposit\_type Non Refund`.
5. **Kemampuan Prediktif:** ROC Curve dengan AUC 0.89 menunjukkan model efektif membedakan antara pembatalan dan non-pembatalan.
6. **Kalibrasi Model:** Calibration Plot menunjukkan prediksi model terkalibrasi dengan baik di rentang probabilitas tengah, meskipun ada deviasi pada probabilitas ekstrem.

# RECOMMENDATION

## MODEL:

- Tambahkan Data: Kumpulkan lebih banyak data pemesanan historis untuk meningkatkan akurasi model.
- Perbaiki Fitur: Buat atau gabungkan fitur baru untuk menangkap informasi lebih dalam tentang pembatalan.
- Optimalkan Hyperparameter: Lanjutkan pengembangan hyperparameter untuk meningkatkan performa model.
- Evaluasi pada Berbagai Data: Uji model pada kelompok data berbeda untuk menemukan area peningkatan.
- Uji Validasi Lebih Luas: Gunakan data dari periode atau lokasi berbeda untuk memastikan model berfungsi baik di berbagai kondisi.

## BUSINESS:

- Gunakan Prediksi untuk Mengelola Kamar: Identifikasi pemesanan berisiko tinggi untuk melakukan overbooking terukur atau menawarkan promosi khusus guna mengurangi pembatalan.
- Kelola Kebijakan Deposit: Tawarkan opsi deposit lebih fleksibel untuk mengurangi risiko pembatalan.
- Segmentasi Pelanggan: Berikan penawaran khusus untuk segmen pelanggan berisiko tinggi guna meningkatkan komitmen mereka.
- Optimalkan Manajemen Waktu Tunggu: Kurangi waktu tunggu untuk mencegah tamu mencari alternatif lain.
- Maksimalkan Konversi Online: Tawarkan insentif tambahan untuk reservasi melalui agen online guna mengurangi pembatalan.
- Tingkatkan Keterlibatan Tamu dari Pasar Utama: Sesuaikan komunikasi dan tawarkan penawaran eksklusif untuk tamu dari pasar dengan risiko pembatalan lebih tinggi.